

Plan de tesis de Licenciatura en Ciencia de Datos

Player Chemistry - Optimización de Vectores Latentes y Métricas de Impacto Conjunto

Bautista Gilardon

bautistagilardon@gmail.com - L.U. 742/21

Director: Manuel Durán

mduran@realracingclub.es

Co-Director: Guillermo Durán

guillermo.duran@de.fcen.uba.ar

Introducción y antecedentes de la temática

El análisis de rendimiento en fútbol ha evolucionado significativamente en las últimas décadas. Durante años, la evaluación de jugadores se basó en estadísticas básicas como goles y asistencias. La introducción de métricas avanzadas como Expected Goals (xG) marcó un punto de inflexión, permitiendo valorar acciones que antes no teníamos en cuenta. Casos de éxito como el Brentford FC, que utilizó analytics para identificar fichajes subvalorados bajo la dirección de Matthew Benham y SmartOdds, demostraron el potencial de las decisiones basadas en datos en el deporte profesional [4].

A pesar de estos avances, la mayoría de las métricas existentes evalúan el rendimiento individual de los jugadores, ignorando un aspecto fundamental: el fútbol es un deporte inherentemente colaborativo. El rendimiento de un jugador depende críticamente de sus compañeros, y la “química” entre jugadores puede determinar el éxito o fracaso de un equipo. Esta limitación es particularmente evidente en procesos de reclutamiento, donde se debe evaluar no solo las cualidades individuales de un potencial fichaje, sino también su capacidad de encajar con los jugadores ya presentes en el plantel.

El trabajo de Bransen y Van Haaren [2] es el primer esfuerzo sistemático por cuantificar el impacto colaborativo entre jugadores mediante las métricas Joint Offensive Impact (JOI) y Joint Defensive Impact (JDI). JOI cuantifica cómo una dupla de jugadores contribuye conjuntamente al ataque, mientras que JDI mide su contribución defensiva. Además del enfoque de cálculo de métricas, se representa a cada jugador como un vector de características que incluye edad, posición, Player Roles, indicadores físicos y otros atributos relevantes. Utilizando estos vectores, se entrenan modelos de aprendizaje automático que predicen el JOI y JDI esperado entre cualquier par de jugadores, incluso si nunca han jugado juntos. Esto permite evaluar la química potencial entre jugadores existentes en un plantel o estimar la compatibilidad con potenciales fichajes.

El trabajo de Bransen y Van Haaren abre camino a investigaciones prometedoras, esta tesis busca explorar algunas. Por un lado, las métricas JOI y JDI evalúan ataque y defensa de forma independiente que es un enfoque natural para el análisis inicial, pero que podría extenderse hacia una métrica unificada que capture la naturaleza dual del fútbol moderno. Por otro lado, el paradigma del paper es evaluar química entre jugadores existentes o candidatos conocidos. Esto plantea una pregunta interesante: ¿podríamos invertir el problema? Es decir, dado un equipo y una posición a cubrir, ¿qué perfil de jugador (qué vector de características) maximizaría la química del conjunto? Esta pregunta transforma el reclutamiento de un proceso reactivo a uno proactivo: primero diseñamos el perfil ideal, luego buscamos jugadores que lo aproximen.

Esta tesis propone extender el trabajo de Player Chemistry en estas dos direcciones complementarias. La línea principal invierte el problema de optimización para identificar vectores de características que maximicen química de equipo bajo restricciones realistas. La línea secundaria diseña métricas que unifiquen dimensiones ofensivo-defensivas. El proyecto se desarrolla en colaboración con Racing de Santander, garantizando acceso a datos reales y validación con profesionales del dominio.

Alcance, actividades y metodología

Alcance del proyecto

El objetivo principal de esta tesis es desarrollar métodos de optimización que identifiquen el perfil ideal de jugador, representado como un vector de características, que maximice la química global de un equipo dado bajo restricciones de posición y formación táctica. Como objetivo secundario, diseñaremos métricas extendidas que unifiquen las dimensiones ofensivo-defensivas del rendimiento colaborativo.

Queda fuera del alcance de este trabajo el desarrollo de métricas en tiempo real o basadas en tracking data, dado que el enfoque se centra en datos de eventos (eventing) ampliamente disponibles.

Metodología

Datos: Utilizaremos datos públicos de eventos futbolísticos de múltiples competiciones, procesados mediante la representación SPADL [3] para estandarización de acciones. Adicionalmente, incorporaremos datos complementarios de Racing de Santander cuando estén disponibles y sean relevantes para la validación de casos de uso.

Replicación del baseline: Como primer paso, implementaremos el cálculo de las métricas JOI y JDI según la metodología descrita en el paper original. Entrenaremos modelos predictivos utilizando CatBoost como baseline, validando la reproducibilidad de los resultados reportados. Esta fase es fundamental para comprender el enfoque original antes de extenderlo.

Optimización de vectores de características: Formularemos matemáticamente el problema de optimización que busca el vector de características que maximice la química de equipo. Exploraremos múltiples enfoques incluyendo optimización por gradiente, algoritmos genéticos y optimización Bayesiana. El problema incorporará restricciones realistas como posición del jugador, compatibilidad con la formación táctica del equipo, y posibles restricciones sobre jugadores considerados “columna vertebral” del plantel. La validación de los perfiles sintetizados se realizará mediante matching con bases de datos reales como FIFA o Transfermarkt, identificando jugadores existentes que más se aproximen al perfil óptimo calculado.

Extensión de métricas: Diseñaremos una métrica unificada que integre las contribuciones ofensivo-defensivas de manera conjunta. Compararemos diferentes arquitecturas de modelos (redes neuronales, gradient boosting mejorado) y validaremos mediante validación cruzada en múltiples competiciones.

Métricas de éxito: El proyecto será evaluado mediante: (1) métricas cuantitativas como RMSE y R^2 en la predicción de química entre jugadores, (2) calidad de los perfiles sintetizados medida por su similitud con jugadores reales exitosos, y (3) utilidad práctica evaluada mediante casos de uso documentados con interpretación de expertos del dominio.

Actividades principales

Las actividades se organizan en seis etapas:

1. **Revisión bibliográfica y preparación:** Estudio exhaustivo de Player Chemistry, VAEP y trabajos relacionados. Configuración del entorno de desarrollo.
2. **Replicación del baseline:** Obtención y procesamiento de datos. Implementación de JOI/JDI y modelos predictivos del paper original.
3. **Desarrollo:** Formulación matemática e implementación de métodos de optimización de vectores. Diseño e implementación de métrica unificada ataque-defensa.

4. **Validación cuantitativa:** Evaluación de ambas contribuciones en múltiples competencias. Comparación contra baselines.
5. **Casos de uso con Racing de Santander:** Aplicación a escenarios reales del club, generación de reportes y validación con directores.
6. **Escritura de tesis y preparación de defensa:** Redacción completa, revisión y correcciones.

Plazos y factibilidad de realización

El proyecto tiene una duración estimada de 16 semanas, comenzando el 17 de marzo de 2025 y finalizando aproximadamente el 30 de junio de 2025, con una dedicación de 20 horas semanales.

Cronograma

Fase 1: Fundamentación y replicación (Semanas 1-4)

Revisión bibliográfica de Player Chemistry, VAEP y trabajos relacionados en optimización y sports analytics. Obtención y procesamiento de datos públicos de eventos mediante representación SPADL. Configuración del entorno de desarrollo y librerías necesarias (socceraction, CatBoost, etc.). Replicación del cálculo de JOI/JDI y entrenamiento de modelos predictivos del paper original. Validación de la reproducibilidad de resultados reportados.

Fase 2: Desarrollo (Semanas 5-11)

Desarrollo paralelo de ambas contribuciones: optimización de vectores de características y diseño de métrica unificada. La formulación matemática del problema de optimización, implementación de algoritmos y validación con bases de datos reales se realizará en paralelo con el diseño, implementación y validación de la métrica extendida ataque-defensa.

Fase 3: Validación y casos de uso (Semanas 12-13)

Aplicación de ambas contribuciones metodológicas a casos de uso reales. Generación de reportes interpretables orientados al cuerpo técnico del club. Validación cualitativa de resultados con ambos directores de tesis, incorporando feedback del dominio futbolístico y académico.

Fase 4: Escritura y defensa (Semanas 14-16)

Redacción completa de la tesis. Preparación de presentación para defensa oral.

Factibilidad

Tengo dirección de Manuel Durán, que es ingeniero de datos de Racing de Santander, lo que me da acceso directo a expertise del dominio y a datos del club. Guillermo Durán como co-director aporta experiencia académica en optimización. Por otro lado, el paper de Player Chemistry tiene código público disponible en GitHub, lo que facilita la replicación inicial y me da un punto de partida sólido. Los datos públicos de eventos están disponibles en múltiples plataformas, así que no hay dependencia crítica de una única fuente. El alcance está pensado de manera modular: si alguna línea se complica, puedo priorizar la optimización de vectores (que es lo principal) sin comprometer la tesis.

Referencias

- [1] BEAL, R., AND RAMCHURN, S. Learning the value of teamwork to form efficient teams. In *Proceedings of the 2019 StatsBomb Innovation in Football Conference* (2019).
- [2] BRANSEN, L., AND VAN HAAREN, J. Player chemistry: Striving for a perfectly balanced soccer team. In *Proceedings of the MIT Sloan Sports Analytics Conference* (2020). arXiv:2003.01712.
- [3] DECROOS, T., BRANSEN, L., VAN HAAREN, J., AND DAVIS, J. Actions speak louder than goals: Valuing player actions in soccer. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (2019), pp. 1851–1861.
- [4] THE ATHLETIC. How brentford’s use of data and analytics made them a premier league force, 2021. Disponible en: <https://theathletic.com>.